

W02B · 언어 모델의 활용 사례

교재 2.1 · 데이터 사이언스를 위한 생성형 인공지능 · 2026-09-09

[Colab 실습 열기](#) · [공통 패키지](#)

이번에 만들 것

문장을 넣으면 토큰과 다음 후보를 보여 주고, 생성 설정을 바꾸거나 영화 리뷰의 감성을 비교할 수 있는 **언어 모델 실험실**을 만든다. 앞선 실험에서 사용한 기능을 마지막에 웹 앱으로 연결한다. 구현은 과목 GitHub의 luna_genai 패키지에 누적하고 노트북과 앱에서 함께 import한다.

이번 수업을 마치면 문자열에서 생성 문장까지의 경로를 설명하고, 같은 모델에 서로 다른 작업을 시키는 프롬프트를 비교할 수 있다. 특히 “높은 확률”, “좋은 문장”, “정답”이 같은 뜻인지 구분한다.

교재에서 가져오는 것은 토큰화·확률 예측·생성·제로샷·퓨샷의 개념과 흐름이다. 아래 예문, 리뷰 데이터, 수치 도식과 웹 앱은 이 수업을 위해 새로 설계했다. Transformer 내부 구조와 가중치를 학습하는 과정은 후속 수업에서 다룬다.

1. 하나의 모델로 어떤 작업을 할 수 있을까?

언어 모델은 주어진 문맥 다음에 올 토큰의 분포를 계산한다. 다음 후보를 선택하고 다시 문맥에 붙이면 문장을 생성할 수 있다. 반대로 문맥 마지막을 Sentiment:처럼 만들고 두 레이블의 점수를 비교하면 간단한 분류 실험이 된다.

활용	입력을 만드는 방법	출력을 읽는 방법
이어 쓰기	이야기의 첫 문장을 제공	새로 생성한 문장 관찰
감성 분류	리뷰와 Sentiment: 제공	positive, negative의 점수 비교
번역	언어 쌍의 예시와 새 문장 제공	대응 문장의 생성을 관찰
요약	원문과 요약 요청 제공	요약 결과를 원문과 대조

번역·요약도 가능한 활용 방식이지만 모든 기본 모델이 요청을 잘 수행하는 것은 아니다. 이번 필수 실험은 이어 쓰기와 감성 분류에 집중한다. 짧은 소형 모델의 출력도 사실 확인과 사람이 읽는 평가가 필요하다.

언어 모델 활용의 공통 경로




그림 1. 교재 2.1의 공통 흐름을 새 예문과 배치로 구성했다. 생성에서는 선택한 토큰을 문맥에 추가하고 다음 분포를 다시 구한다.

실습은 교재와 같은 **Qwen/Qwen2-0.5B 기본 모델**을 사용한다. instruction-tuned 대화 모델과 구분되는 모델이며, 내부 확률을 관찰하기 위한 선택이다. 제공자도 기본 모델을 완성형 텍스트 생성 서비스로 사용하는 것을 권장하지 않는다. [Qwen2-0.5B 모델 설명](#)

준비하고 예측하기

Colab 사본을 저장하고 첫 설치 셀부터 실행한다. 공개 모델 약 1 GB를 처음 한 번 내려받고, 자체 작성 리뷰 데이터는 패키지를 설치할 때 함께 준비한다. 유료 API 키나 파일 업로드는 필요 없다. CPU가 기본이며 사용 가능한 GPU가 있으면 활용한다. 모델은 `lab = LanguageModelLab()`로 한 번 만들고 이후 셀에서 재사용한다.

모델 로딩이 실패하면 오류를 확인한 뒤 다시 실행한다. 인터넷 없이 진행할 때는 노트북과 앱의 **수치 실험 전용 모드**를 사용할 수 있다. 이 모드의 네 후보는 직접 정한 가상 로짓이며, 실제 언어 모델의 예측이 아니다. 패키지 설치까지 실패했다면 인터넷 연결부터 복구해야 한다.

실행 전 질문: The movie was 다음에는 어떤 단어가 높은 점수를 받을까? 문맥에 boring을 추가하면 같은 분포가 나올까?

2. 토큰화: 모델은 글자를 어떻게 받는가?

토큰화(tokenization)는 문자열을 모델이 사용하는 작은 단위로 나누고 ID로 바꾸는 과정이다. 문자 단위는 어휘가 작지만 문장이 길어질 수 있고, 단어 단위는 처음 보는 단어를 처리하기 어렵다. 하위 단어(subword)는 자주 나타나는 조각을 재사용한다. 실제 알고리즘은 모델별로 다르며 모델과 대응하는 토큰라이저를 함께 사용해야 한다. [Transformers 토큰화 설명](#)

토큰은 단어와 항상 같지 않다

문자 단위 예



단어 단위 예



실제 Qwen2 토큰



입력: A cat naps. / 토큰 상자의 ·는 앞 공백 표시. 실제 ID는 노트북에서 확인.

그림 2. 교재 그림 2-1~2-3의 단위 비교를 새 예문 A cat naps.로 구성했다. 마지막 행은 고정된 Qwen2 토큰 나이저의 실제 결과이다. 토큰 상자의 ·는 앞 공백을 읽기 쉽게 표시한 기호이다.

```
from luna_genai import LanguageModelLab
lab = LanguageModelLab()
lab.token_table("A cat naps.")
```

이 예문의 ID는 해당 revision에서 [32, 8251, 308, 2625, 13]이다. 숫자는 뜻의 순서나 중요도를 나타내지 않는 어휘표의 식별자이다. cat과 cat의 ID가 다른 이유는 공백도 입력의 일부이기 때문이다. 같은 영어 단어를 다른 모델에 넣으면 다른 ID가 나올 수 있다.

한국어도 직접 관찰한다. 일부 토큰은 한 글자의 바이트 일부에 대응하므로 토큰 하나씩 decode하면 대체 문자 $\diamond$ 가 보일 수 있다. 개별 decode 결과를 이어 붙이는 방식과 **전체 ID를 한 번에 decode하는 방식**을 구분한다. 정상적인 전체 복원 여부는 후자로 확인한다.

실습 A · 예측 → 실행 → 복원

1. cat, cat, 고양이가 잠을 잡니다.의 토큰 수를 먼저 예상한다.
2. 표의 ID·내부 표기·개별 decode를 관찰한다.
3. 전체 ID를 복원하여 원문과 같은지 검사한다.

빈칸 문제: 노트북의 recovered_student에 전체 ID를 복원한 문자열을 넣는다. **목표:** encode와 decode의 관계 이해. **힌트:** 토큰나이저의 decode는 ID 목록을 받는다. **자가 점검:** 복원 문자열이 원문과 같아야 한다. 문제를 아직 풀지 않아도 뒤 실험은 실행할 수 있다.

3. 다음 토큰의 로짓과 확률

모델 출력의 로짓(logit)은 각 후보에 부여한 정규화 전 점수이다. 음수일 수 있고 합이 1일 필요도 없다. softmax는 점수를 양수로 바꾸고 전체 합으로 나누어 확률 분포를 만든다.

$$p(i \mid \text{문맥}) = \exp(z_i) / \sum_j \exp(z_j)$$

분모는 전체 어휘 후보를 포함한다. 실무 계산에서는 큰 수의 지수로 인한 넘침을 피하려고 모든 점수에서 최대값을 빼고 계산한다. 분자와 분모에 같은 상수가 곱해지므로 결과 분포는 같다.

모델 출력 형태는 [배치, 입력 위치, 어휘 후보]이다. 문장 하나의 다음 토큰을 보려면 마지막 입력 위치를 읽는다. Python 인덱스 -1은 마지막 원소를 뜻한다.

```
z = lab.last_logits("The movie was")
top = lab.next_tokens("The movie was", n=8)
```

표의 확률은 전체 어휘로 정규화한 값이다. 화면에는 8개 후보만 보이므로 **보이는 확률의 합이 1보다 작을 수 있다**. 나머지 후보의 확률을 버리고 8개끼리 다시 정규화한 표와는 의미가 다르다. 또한 모델 확률은 이 문맥 다음에 나올 토큰의 확률이며 그 내용이 사실이라는 확률이 아니다.

실습 B · 문맥 바꾸기와 인덱스 디버깅

The movie was와 The movie was boring and의 상위 후보를 비교한다. 같은 후보의 순위가 달라졌는지 기록한다. 결과가 예상과 달라도 관찰을 그대로 남긴다.

디버깅 문제: 가상 출력 fake_logits의 형태가 (1, 3, 4)일 때 fake_logits[0, 0, :]는 어느 위치를 읽는가? 마지막 위치의 후보 4개를 읽도록 last_student를 작성한다. **힌트:** 세 축의 의미와 -1. **자가 점검:** 결과 형태가 (4,)이고 첫 위치의 값과 다른지 확인한다.


4. 생성은 선택과 반복이다

자동회귀 생성(autoregressive generation)은 다음 후보 선택 → 문맥에 추가 → 새 분포 계산을 반복한다. 같은 첫 분포에서 시작해도 선택 규칙에 따라 이후 문맥이 달라지고, 뒤의 분포도 달라진다. 비교할 때 프롬프트·모델·생성 길이를 유지한다.

탐욕적 디코딩과 빔 검색

탐욕적 디코딩(greedy decoding)은 매 단계 가장 확률이 높은 후보 하나를 선택한다. 빠르고 결정적이지만 문장 전체의 높은 점수를 보장하지 않는다. 빔 검색(beam search)은 여러 부분 문장을 유지하며 확장한다. 탐색 폭과 점수 규칙에 따라 결과가 달라지고, 탐욕적 방법보다 계산이 늘어난다.

처음 가장 높은 후보가 전체 최선은 아닐 수 있다



가상 확률 예. 선택된 후속 후보가 나머지 확률을 차지한다. 빔 검색도 항상 전역 최적을 보장하지 않는다.

그림 3. 교재 그림 2-4~2-5의 탐색 개념을 새로운 두 단계 확률로 설명한다. 다른 후속 후보들은 생략했다. 실제 문장 점수는 토큰별 로그 확률의 합 등으로 계산하며 길이 보정 여부도 중요하다. 제한된 빔 폭은 전역 최적의 보장이 아니다.

```
lab.generate("A small robot opened the door and", strategy="greedy")
```

우리 패키지의 greedy는 `do_sample=False`이고, beam은 폭 3·길이 보정 0으로 설정한다. 빔 검색은 이번에는 짧은 시연으로 관찰한다. 높은 모델 점수만으로 사람이 읽기 좋은 문장이 보장되지는 않는다. [Transformers 생성 방식](#)

샘플링과 temperature

샘플링은 분포에 따라 다음 후보를 무작위로 뽑는다. temperature T 는 softmax 이전에 로짓을 나누는 양이다. $p(i) = \text{softmax}(z/T)$ 로 계산하며 T 가 작으면 높은 후보에 더 집중하고, T 가 크면 더 평평해진다. 순위 자체는 양수 T 로 나누기만 해서는 바뀌지 않는다.

같은 가상 로짓 [3, 2, 1, 0]을 temperature로 나누면




그림 4. 교재 그림 2-6~2-7의 샘플링·temperature 관계를 직접 계산한 분포로 재구성했다. $T=0.5$ 에서 A에 더 집중하고 $T=2$ 에서는 다른 후보도 선택될 여지가 커진다.

T 가 0에 가까워지는 극한과 API에 숫자 0을 넣는 것은 다르다. 이 실습의 샘플링 T 는 양수만 허용한다. 가장 높은 후보만 고르려면 `strategy="greedy"`를 사용한다. 높은 T 는 정확도를 높이는 장치가 아니며, 낮은 T 도 사실성을 보장하지 않는다.

top-k와 top-p

top-k는 확률이 높은 k 개를 남긴다. top-p(nucleus sampling)는 확률순으로 더하여 누적 확률이 p 이상이 되는 최소 후보 집합을 남긴다. 임계값을 처음 넘기는 토큰을 포함한 뒤 다시 정규화한다. [Nucleus sampling 논문 초록](#)

top-k는 개수, top-p는 누적 확률로 후보를 남긴다

A 0.644

B 0.237

C 0.087

D 0.032

기본 분포: $\text{softmax}([3,2,1,0])$ 의 반올림 표시

top-k = 2 $\rightarrow$ A, B

top-p = 0.80 $\rightarrow$ A, B

남긴 후 확률: A 0.731 / B 0.269

A만 $0.644 < 0.80 \leq A+B 0.881$

두 필터는 이 예에서만 같은 집합을 만든다. top-p는 임계값을 처음 넘기는 후보까지 포함한다.

그림 5. 교재 그림 2-8의 후보 제한 관계를 새 수치로 설명한다. 이 분포에서는 두 필터가 같은 집합을 만들지만 일반적으로 같지 않다. top-p의 후보 개수는 문맥에 따라 달라진다.

우리 패키지는 top_k=0, top_p=1로 각 필터를 해제한다. temperature만 비교할 때는 두 필터를 해제한다. top-k만 비교할 때는 top_p=1을, top-p만 비교할 때는 top_k=0을 유지한다. 둘을 함께 켜면 top-k 필터 다음 top-p를 적용하므로 한 가지 효과만 보려는 실험과 구분한다.

실습 C · 한 조건만 바꾸기

같은 시작 문장·seed 7·생성 길이에서 T=0.5와 T=1.2를 비교한다. 다음에는 T=0.8을 고정하고 top_p=1과 0.8을 비교한다. 마지막으로 같은 설정과 seed로 다시 실행한다. 서로 다른 설정이 반드시 서로 다른 문장을 만드는 것은 아니다.

목표: 반복 가능성과 다양성을 구분. **힌트:** seed는 무작위 추출의 시작 상태이며 모델의 지식을 바꾸지 않는다. **자가 점검:** 바꾼 설정은 한 가지인가? 같은 환경에서 같은 설정을 반복했는가? GPU·라이브러리 버전이 달라지면 동일 seed만으로 완전히 같은 결과를 보장할 수 없다.

5. 제로샷과 퓨샷: 문맥으로 작업을 제시하기

제로샷(zero-shot)은 작업 예시 없이 요청과 입력을 제공한다. 퓨샷(few-shot)은 소수의 입력·출력 예시를 문맥에 추가한다. 이번 2-shot에서는 고정된 리뷰·레이블 예시 2개를 넣는다. **모델의 가중치를 업데이트하지 않는다.** 프롬프트에 예시를 넣는 것과 학습 데이터로 미세조정하는 것은 다르다. [Few-shot 학습 논문 초록](#)

```
Classify the movie review as positive or negative.  
Review: Wonderful acting made this a lovely evening.  
Sentiment:
```

이 뒤의 positive와 negative 점수를 비교한다. 앞 공백까지 포함한 문자열을 실제 토큰아이저로 변환하고, 각각 한 토큰인지 검사한다. 교재에 나온 ID 숫자를 다른 모델에 그대로 쓰지 않는다. 레이블이 여러 토큰이라면 전체 레이블의 조건부 확률을 계산해야 하며, 마지막 토큰 하나만 비교해서는 안 된다.

두 레이블 내 비율을 정확히 읽기

전체 어휘에서 두 레이블의 확률을 각각 p_{pos} , p_{neg} 라고 하면 양성의 상대 점수는 $p_{\text{pos}} / (p_{\text{pos}} + p_{\text{neg}})$ 이다. 이는 “다음 토큰을 두 레이블로 제한했을 때의 비율”이다. 다른 단어가 대부분의 확률을 차지해도 이 비율은 높을 수 있다. 따라서 앱은 전체 어휘 확률과 두 후보 내 비율을 함께 보여 준다.

예를 들어 두 확률이 0.018과 0.002라면 상대 점수는 0.9이지만, 두 후보가 차지한 전체 확률은 0.02뿐이다. 이 수치는 설명용 가상 예이며 “90% 확률로 정답”이라는 뜻이 아니다.

```
from luna_genai import load_reviews
review = load_reviews("development")[0]["review"]
result = lab.classify(review, few_shot=True)
print(result["prompt"])
result["scores"]
```

실습 D · 같은 평가 문장으로 비교


데이터는 모두 직접 작성한 짧은 영어 영화 리뷰이다. examples의 2개는 프롬프트용, development의 4개는 실험·조정용, evaluation의 4개는 조정 후 마지막 비교용이다. 외부 IMDb 데이터나 교재의 원자료가 아니다.

개발 문장으로 프롬프트를 살펴본 뒤, 평가 4개에 제로샷과 2-shot을 같은 조건으로 적용한다. 정답 수와 함께 두 레이블의 전체 확률 질량을 살펴본다. 퓨샷이 항상 더 정확하다고 가정하지 않는다. 4개 결과가 같거나 전부 맞아도 일반 성능의 근거는 충분하지 않다.

오류 찾기: 부정어, 반어, 장단점을 섞은 자체 문장 하나를 추가한다. 오분류하면 문장 해석·프롬프트·레이블 방식 중 무엇을 바꿔 확인할지 제안한다. 오분류를 발견하지 못했으면 “현재 예에서는 발견하지 못함”이라고 기록한다. 결과를 맞추려고 평가 문장을 반복해서 조정하면 더 이상 미사용 평가가 아니다.

6. 마지막 통합 실습 · 언어 모델 실험실 만들기

하나의 공통 패키지, 두 개의 사용 화면



학생 확장: 입력 컴포넌트 → 직접 작성한 callback → 출력 컴포넌트 연결

그림 6. 새로 설계한 누적 앱 구조. 화면은 입력과 출력을 담당하고, 모델·데이터 처리는 공통 패키지가 담당한다.

```
from luna_genai import build_app
app = build_app(lab)
app.launch(share=True) # Colab에서 실행
```

앱에는 토큰·다음 후보, 생성 비교, 제로샷·퓨샷 분류, 수치 실험 탭이 있다. 같은 lab을 넘기므로 버튼을 누를 때마다 모델을 다시 다운로드하지 않는다. 모델이 없으면 수치 실험 전용 앱을 만들어 현재 모드를 화면에 표시한다.

Gradio Blocks에서는 컴포넌트를 만들고 이벤트에 함수를 연결한다. `button.click(fn, inputs, outputs)`의 입력 컴포넌트 순서는 함수 인수 순서에 대응하고, 함수 반환값은 출력 컴포넌트에 전달된다. 함수는 화면 객체가 아닌 실제 입력값을 받는다. [Gradio 공식 Blocks 가이드](#)

실습 E · 나의 비교 패널 연결

완성된 기본 앱을 먼저 확인한 뒤 노트북의 확장 문제를 푼다. 사용자가 입력한 문장의 토큰 수를 반환하는 callback을 작성하고, 새 탭에 Textbox·Button·Number를 배치해 연결한다.

목표: UI 입력 → 공통 API → 반환값 → UI 출력의 흐름을 직접 구성. **힌트:** `lab.token_table(text)`의 행 수와 함수 반환값의 자료형을 생각한다. **자가 점검:** 두 다른 문장을 넣었을 때 입력에 대응하는 숫자가 나타나는가? 버튼의 inputs와 outputs가 함수에 맞게 연결되었는가? 전체 모델 로드를 callback 안에서 반복하지 않는가?

확장 문제를 마치지 않아도 기본 앱의 기능을 실행할 수 있다. 앱에서 최소 두 탭을 실제 조작하고, 모바일 폭에서는 컴포넌트가 어떻게 쌓이는지 관찰한다. Colab 공유 링크는 실행 중인 런타임에 연결되므로 런타임 종료 후에는 다시 실행해야 한다.

7. 실험 기록과 점검 퀴즈

노트북의 기록 셀 또는 [실험 기록 양식](#)에 남긴다. 이번 자료에는 별도 성적 반영 과제가 없다.

기록할 항목	작성 내용
실행 조건	모델 revision·패키지 버전·CPU/GPU·seed
비교	같은 입력에서 한 가지 바꾼 설정
관찰	실제 생성 문장 또는 후보·레이블 점수
해석	관찰로 말할 수 있는 것과 아직 확인하지 못한 것
앱	입력·callback·출력 연결과 확인한 동작

1. cat과 cat의 토큰 ID가 다를 수 있는 이유는 무엇인가?
2. 출력 형태가 [배치, 위치, 어휘]일 때 다음 토큰 분포를 읽는 위치는 어디인가?
3. 상위 후보 8개의 확률 합이 1보다 작은 것이 오류인가?
4. temperature만 비교하려면 top-k와 top-p를 어떻게 설정하는가?
5. 확률이 0.60, 0.25, 0.10, 0.05일 때 top-p=0.80은 몇 개를 남기는가?
6. 퓨샷 프롬프트에 예시 2개를 추가하면 모델 가중치가 업데이트되는가?
7. 두 레이블 내 양성 비율이 0.9이면 90% 확률로 정답이라고 말할 수 있는가?
8. 웹 앱의 버튼 callback 안에서 모델을 매번 다시 로드하면 어떤 문제가 생기는가?

먼저 답을 작성한 뒤 [별도 퀴즈 해설](#)로 확인한다.

참고자료와 재구성 범위

- 주교재 『핸즈온 생성형 AI』 2.1 언어 모델의 활용 사례, 인쇄 p.44~67, 그림 2-1~2-8. 원문의 토큰화·확률 예측·생성·제로샷·퓨샷 용어와 흐름을 따른다. 도식 1~5는 개념을 참고해 새 예문·수치·배치로 독립 제작했고 도식 6과 리뷰·앱은 수업용 추가 설계이다.
- [Qwen2-0.5B](#), [토큰화 문서](#), [생성 문서](#): 모델 선택과 API 설명.
- [Holtzman 외](#), [The Curious Case of Neural Text Degeneration](#), [Brown 외](#), [Language Models are Few-Shot Learners](#): 초록의 nucleus sampling 동기와 가중치 업데이트 없는 few-shot 개념 참고. 이 논문들의 실험 결과를 이번 소형 모델의 성능 보장으로 사용하지 않는다.
- [Transformers 5.15.1 Qwen2 API](#), [Gradio Blocks](#): 설치 버전·이벤트 연결 확인. 외부 자료 확인일 2026-09-08.