

언어 모델의 활용 사례 · 퀴즈 해설

W02B 강의노트의 8개 점검 질문에 대응하는 수업용 자체 해설. 먼저 문제를 풀어 본 뒤 확인한다.

1. cat과 cat의 토큰 ID가 다를 수 있는 이유는 무엇인가?

공백도 입력의 일부이며 토큰라이저가 앞 공백을 포함한 조각을 별도 토큰으로 사용할 수 있기 때문이다. ID는 해당 모델 어휘표의 식별자이므로 다른 모델에 그대로 전용할 수 없다.

2. 출력 형태가 [배치, 위치, 어휘]일 때 다음 토큰 분포를 읽는 위치는 어디인가?

문장 하나라면 `logits[0, -1, :]`로 마지막 입력 위치의 전체 어휘 벡터를 읽는다. `[0, 0, :]`는 첫 위치이고, 마지막 어휘 원소 하나를 선택하는 것도 다르다.

3. 상위 후보 8개의 확률 합이 1보다 작은 것이 오류인가?

오류가 아니다. 분모는 전체 어휘이며 화면은 상위 8개만 보여 준다. 보이지 않는 후보도 확률을 가진다. 8개끼리 재정규화한 조건부 표와 구분해야 한다.

4. temperature만 비교하려면 top-k와 top-p를 어떻게 설정하는가?

이 패키지에서는 `top_k=0, top_p=1`로 두 필터를 해제한다. 프롬프트·seed·최대 새 토큰 수를 유지하고 T만 바꾼다. greedy는 sample용 설정을 사용하지 않는다.

5. 확률이 0.60, 0.25, 0.10, 0.05일 때 top-p=0.80은 몇 개를 남기는가?

확률순 첫 2개를 남긴다. 첫 후보만으로는 $0.60 < 0.80$ 이고 두 번째까지 $0.85 \geq 0.80$ 이다. 임계값을 처음 넘기는 후보까지 포함한다. 남긴 후보는 $0.60/0.85$ 와 $0.25/0.85$ 로 다시 정규화한다.

6. 퓨샷 프롬프트에 예시 2개를 추가하면 모델 가중치가 업데이트되는가?

아니다. 이번 퓨샷은 입력 프롬프트에 예시 2개를 추가할 뿐, gradient update나 optimizer step을 수행하지 않는다. 미세조정과 구분한다.

7. 두 레이블 내 양성 비율이 0.9이면 90% 확률로 정답이라고 말할 수 있는가?

그렇게 말할 수 없다. 다음 토큰을 두 레이블로 제한한 상대 비율이며 정답 여부에 대해 보정된 확신도가 아니다. 두 레이블이 전체 어휘에서 차지하는 확률 질량과 별도 평가도 확인해야 한다.

8. 웹 앱의 버튼 callback 안에서 모델을 매번 다시 로드하면 어떤 문제가 생기는가?

불필요한 다운로드 확인·모델 로딩·메모리 할당이 반복되어 응답이 느려지고 자원을 낭비한다. 노트북/앱 시작 때 한 번 만든 lab을 callback이 재사용한다. 화면 입력과 함수 반환값의 연결은 별도로 구성한다.