

트랜스포머 블록과 사전학습: 모델 계보에서 텍스트 생성 웹앱까지 · 퀴즈 해설

W03A 강의노트 Q1-Q10에 대응하는 수업용 자체 해설. 먼저 풀어 본 뒤 확인한다.

1. 토큰 ID와 임베딩 벡터는 어떻게 다른가?

ID는 어휘표의 식별 번호이고 임베딩은 그 번호로 조회하는 학습 가능한 실수 벡터다. ID 크기에 의미의 크기가 담긴 것은 아니다. 같은 시작 임베딩도 블록 이후 문맥 표현은 달라질 수 있다.

2. QK 전치의 3행 2열은 무엇을 뜻하는가?

세 번째 위치의 Query와 두 번째 위치의 Key를 내적한 점수다. 세 번째 위치가 두 번째 위치를 얼마나 참고할지 결정할 재료이며, 아직 softmax 확률이나 Value 가중합은 아니다.

3. 미래 위치의 점수를 0으로 바꾸는 것이 올바른 causal mask인가?

아니다. $\exp(0)$ 은 1이므로 차단되지 않는다. softmax 이전에 미래 점수에 음의 무한대를 더하거나 매우 작은 값으로 설정한다. 대각선과 이전 위치는 허용한다.

4. 어텐션 가중치의 softmax 축과 언어 모델 출력 softmax 축은 어떻게 다른가?

어텐션은 한 Query 위치가 참고할 입력 위치들 사이에서 행별 정규화한다. 언어 모델 출력은 다음 토큰 후보인 전체 어휘 사이에서 정규화한다. 화면에 표시한 일부 어휘 후보의 합만으로 1을 요구하면 안 된다.

5. FFN은 서로 다른 토큰 위치의 정보를 직접 섞는가?

기본 위치별 FFN은 각 위치에 같은 함수를 독립 적용해 특징을 변환한다. 서로 다른 토큰 위치의 정보 혼합은 어텐션이 담당한다. FFN의 폭은 확장 후 다시 원래 폭으로 축소하여 잔차 합이 가능하게 한다.

6. BERT, Qwen, T5를 각각 어떤 구조 계열로 분류하는가?

BERT는 encoder-only, Qwen은 decoder-only, T5는 encoder-decoder다. T5가 문장을 생성한다는 이유로 decoder-only로 분류하면 안 된다. 기본·지시 튜닝 구분은 구조 계열과 별개의 축이다.

7. 정답 다음 토큰에 확률 0.2를 준 경우와 0.8을 준 경우 중 손실이 더 큰 것은 어느 쪽인가?

자연로그 음의 로그손실은 확률 0.2에서 약 1.609, 0.8에서 약 0.223이므로 0.2 쪽이 더 크다. 정답에 높은 확률을 줄수록 손실은 작아진다.

8. few-shot 예시를 입력에 추가하면 모델 가중치가 자동으로 업데이트 되는가?

아니다. 추론에서 프롬프트와 문맥 표현은 달라지지만 gradient와 optimizer step이 없으면 가중치는 갱신되지 않는다. 데이터로 가중치를 추가 학습하는 미세조정과 구분한다.

9. 생성 루프에서 매번 전체 출력 문자열을 다시 토큰화하지 않고 ID를 이어 붙이는 이유는 무엇인가?

이미 선택한 토큰 시퀀스를 그대로 유지하기 위해서다. 개별 조각 decode와 문자열 결합 후 재토큰화는 같은 ID열을 보장하지 않는다. ID를 이어 붙이고 마지막에 전체를 decode한다.

10. KV 캐시를 사용하면 다음 토큰들을 모두 동시에 결정할 수 있는가?

아니다. 이미 계산한 이전 위치의 K/V를 재사용하여 중복 계산을 줄일 뿐, 새 토큰 선택에 따른 다음 문맥의 의존성은 남는다. 캐시는 임시 추론 상태이며 학습된 모델 가중치가 아니다.