

W03B · 트랜스포머 구조 다시 보기

2026년 9월 16일 수요일 · 생성형 인공지능 · 3주차 2차시 보강

교재 2장 2.2–2.7 / W03A를 마쳤다고 가정하지 않습니다. 오늘의 목표는 **블록 안에서 무엇이 바뀌는지 설명하고, 그 블록을 가진 실제 모델로 한 토큰씩 누적하는 웹앱을 만드는 것**입니다.

[단계별 Colab](#) · [실험 기록](#) · [지난 강의](#)

1. 먼저 세 가지를 구별합니다

“나는 오늘 학교에”라는 문장이 토큰화되었다고 합시다. 실제 토큰라이저는 한 단어를 여러 조각으로 나눌 수 있으므로, 아래 단어 단위 예시는 원리 설명용입니다.

대상	무엇인가	변하는 때
토큰 ID	어휘표의 번호. 크고 작은 숫자가 의미의 크기를 뜻하지 않음	새 토큰을 추가하면 ID열이 길어짐
임베딩	ID로 조회한 실수 벡터	학습 때 임베딩 표의 값이 바뀜
문맥 표현	블록을 지나 주변 정보를 반영한 벡터	입력 문맥과 블록에 따라 달라짐

블록 입력 $X \in \mathbb{R}^{n \times d}$ 의 **행**은 토큰 위치, **열**은 특징입니다. 오늘 손계산은 $n = 3, d = 4$ 입니다. 블록은 대체로 이 모양을 보존하면서 각 행의 내용을 더 유용하게 바꿉니다. 배치 축은 그림에서 생략합니다.

2. 큰 구조도: 선을 따라 읽기




그림 출처: Vaswani et al., *Attention Is All You Need*, Figure 1. [원논문](#) / [원본 이미지](#). 원논문에 명시된 출처 표시 조건부 학술적 재사용 허용에 따라 원본 그대로 사용했습니다. 교재 그림 2-10의 원출처이며, 출판사의 번역·편집 이미지를 복제한 것은 아닙니다.

그림은 **아래에서 위로** 읽습니다. 영어 상자 이름보다 다음 경로를 먼저 짚으세요.


1. 왼쪽 **Inputs** → **Input Embedding**: 원문 토큰 ID를 벡터로 바꿉니다. Positional Encoding을 더해 순서 정보를 줍니다. 어텐션 자체만으로는 위치 순서를 알 수 없기 때문입니다.
2. 왼쪽 회색 테두리 $N \times$: self-attention과 FFN을 가진 인코더 블록을 여러 층 쌓습니다. 같은 모양의 층이지, 모든 층이 동일한 가중치를 공유한다는 뜻은 아닙니다.
3. 오른쪽 **Outputs (shifted right)**: 학습에서는 정답 출력의 이전 토큰들을 넣습니다. 추론에서는 시작 토큰과 지금까지 생성한 토큰을 넣습니다.
4. 오른쪽 첫 어텐션은 **Masked Multi-Head Attention**입니다. 현재 위치에서 미래 출력은 보지 않습니다. 두 번째 어텐션은 왼쪽 인코더 출력도 받아 원문을 참고하는 **cross-attention**입니다.
5. 오른쪽 맨 위 **Linear** → **Softmax**: 출력 벡터를 전체 어휘 후보의 점수로 바꾸고 다음 토큰 분포를 만듭니다. 어텐션 안의 softmax와는 대상 축이 다릅니다.

그림의 가느다란 우회선은 장식이 아닙니다. 각 하위층에 들어가기 전 값을 보관했다가 계산 결과에 더하는 **잔차 연결**입니다. GPT/Qwen은 이 전체 번역 구조를 그대로 쓰지 않습니다. 별도 인코더와 그 출력에 대한 cross-attention이 없는 decoder-only 계열입니다.

3. 한 블록을 끝까지: 섞기 → 보존하기 → 특징 바꾸기

원논문 post-LN 블록: 아래에서 위로 읽기

다음 블록으로 (각 블록 가중치는 별도)



자체 제작. 원논문 post-LN 기준입니다. 입력과 각 결과의 모양은 모두 3×4 여서 더할 수 있습니다.

3.1 어텐션: 다른 위치의 정보를 받아옵니다

각 위치가 다른 위치를 얼마나 참고할지 계산하고, 그 비중으로 정보를 섞습니다. “그것”이 어느 대상을 가리키는지 판단할 때 주변 단어 표현을 참고하는 상황을 떠올려 보세요. 다만 어텐션 비중을 사람처럼 이해했다는 증거나 유일한 설명으로 해석해서는 안 됩니다.

3.2 잔차: 원래 표현에 수정량을 더합니다

$$R_1 = X + \text{MHA}(X), \quad U = \text{LN}(R_1)$$

X 는 지우지 않고 우회선에 남겨 둡니다. 어텐션 결과는 원래 표현에 보탬 정보입니다. 이어 붙이기(concat)가 아니라 같은 위치·같은 특징끼리 덧셈합니다. 잔차 경로는 깊은 모델의 정보·기울기 전달을 돕습니다.

3.3 LayerNorm: 한 위치 안의 특징 스케일을 조정합니다

한 행 $r = (r_1, \dots, r_d)$ 에 대해

$$\mu = \frac{1}{d} \sum_j r_j, \quad \sigma^2 = \frac{1}{d} \sum_j (r_j - \mu)^2,$$


$$\text{LN}(r)_j = \gamma_j \frac{r_j - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta_j.$$

평균을 빼고 표준편차로 나눈 뒤 학습 가능한 크기 γ 와 이동 β 를 적용합니다. ϵ 은 0으로 나누는 것을 막는 작은 양수입니다. 여러 토큰의 평균을 내어 같은 값으로 만드는 연산도, 확률의 합을 1로 만드는 softmax도 아닙니다. 손계산에서는 $\gamma = 1, \beta = 0$ 으로 둡니다.

3.4 FFN: 같은 위치의 특징을 가공합니다

$$F = \max(0, UW_1 + b_1)W_2 + b_2, \quad Y = \text{LN}(U + F).$$


FFN: 행 사이 이동 없이, 각 행의 특징만 변환



자체 제작. 예시에서 $W_1 : 4 \times 6$, $W_2 : 6 \times 4$ 입니다. $3 \times 4 \rightarrow 3 \times 6 \rightarrow 3 \times 4$ 로 폭을 늘렸다 되돌립니다. ReLU는 음수를 0으로 만드는 비선형 함수입니다. 비선형성이 없다면 두 선형 변환을 하나로 합칠 수 있습니다.

모든 위치에 **동일한 FFN 가중치**를 적용하지만 행 사이 값을 직접 섞지는 않습니다. 어텐션은 위치 간 정보 교환, FFN은 위치별 특징 변환이라는 역할을 구별하세요. 마지막 Y 가 다음 블록의 입력이 됩니다.

4. 어텐션을 한 행씩 계산하기



자체 제작. Q/K/V는 세 종류의 단어가 아니라 같은 입력을 서로 다른 용도로 투영한 벡터입니다.

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V.$$

Query는 “지금 위치가 찾는 단서”, Key는 “각 위치가 비교에 내놓는 단서”, Value는 “실제로 가져올 정보”라는 비유로 읽습니다. W_Q, W_K, W_V 는 학습됩니다. 사람이 검색어를 직접 써 넣거나 단어 뜻을 수작업으로 분류하는 것이 아닙니다.

4.1 손계산 예제: 세 위치, head 폭 2

아래는 학습된 모델에서 추출하지 않은 교육용 숫자입니다. 노트북의 `block_walkthrough()`와 같습니다.

$$Q = K = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}, \quad V = \begin{bmatrix} 1 & 0 \\ 0 & 2 \\ 3 & 1 \end{bmatrix}.$$

$$S = \frac{QK^T}{\sqrt{d_k}} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 2 \end{bmatrix}.$$

S_{ij} 는 정보를 받는 위치 i 의 Query와 참고하는 위치 j 의 Key의 내적입니다. $\sqrt{d_k}$ 로 나누는 이유는 head 폭이 커질 때 내적 크기가 커져 softmax가 지나치게 뾰족해지는 경향을 줄이기 위해서입니다.


4.2 두 번째 위치만 확대합니다

마스크 전 두 번째 행은 $[0, 0.7071, 0.7071]$ 입니다. causal 조건에서는 위치 2가 위치 3을 보면 안 되므로

$$[0, 0.7071, -\infty] \xrightarrow{\text{softmax}} [0.3302, 0.6698, 0].$$

$$A_{ij} = \frac{\exp(S_{ij} + M_{ij})}{\sum_k \exp(S_{ik} + M_{ik})}, \quad M_{ij} = \begin{cases} 0 & j \leq i \\ -\infty & j > i. \end{cases}$$

분모는 **같은 행의 참고 위치들**을 더합니다. 위치 2 자신은 볼 수 있습니다. 미래 점수를 0으로 바꾸면 $\exp(0) = 1$ 이므로 차단되지 않습니다.




자체 제작. 각 행의 합은 1입니다. 세 번째 위치는 이미 마지막이어서 마스크 전후가 같습니다. 첫 번째 위치는 자기 자신만 참고하여 $[1, 0, 0]$ 이 됩니다.

마지막으로 Value를 가중합합니다.

$$z_2 = 0.3302[1, 0] + 0.6698[0, 2] + 0[3, 1] = [0.3302, 1.3395].$$


이 값은 토큰 번호도 다음 단어 확률도 아닙니다. 두 번째 위치에 전달할 새 특징 벡터입니다. 모든 행을 한꺼번에 계산하면

$$Z = AV, \quad (3 \times 3)(3 \times 2) = 3 \times 2.$$



출처: Vaswani et al., Figure 2 왼쪽, [원본](#), 원본 그대로 학술적 재사용. 아래 Q/K에서 시작해 MatMul → Scale → Mask → SoftMax → V와 MatMul 순서를 위쪽으로 짚으세요.


5. 여러 head는 병렬로 계산하고 열 방향으로 합칩니다



자체 제작. head 1이 계산된 뒤 head 2를 실행하는 직렬 관계가 아닙니다. 각 head는 서로 다른 투영 가중치를 가집니다. 특정 head가 언제나 특정 문법만 맡는다고 정해져 있지는 않습니다.

$$\text{MHA}(X) = \text{Concat}(Z_1, \dots, Z_h)W_O.$$


예시에서는 두 3×2 를 특징 열 방향으로 합쳐 3×4 로 만들고, $W_O \in \mathbb{R}^{4 \times 4}$ 로 head들의 정보를 섞습니다. 원래 X 와 폭이 같아져 잔차 합이 가능합니다. concat 때 위치 수 3을 6으로 늘리지 않습니다.



출처: Vaswani et al., Figure 2 오른쪽, [원본](#), 원본 그대로 학술적 재사용. 아래 세 Linear는 Q/K/V 투영, 위 Linear는 결합 후 출력 투영입니다.


원논문 그림과 실제 Qwen을 구별하기

정규화 위치와 종류를 섞어 그리지 않기



자체 제작. 실제 실습 모델 Qwen2는 하위층 앞의 RMSNorm, 위치 정보를 주는 RoPE, K/V head를 공유하는 GQA, SwiGLU FFN을 사용합니다. RMSNorm은 LayerNorm처럼 평균을 빼는 방식이 아닙니다. 이번 손계산은 원리를 보기 위한 post-LN/ReLU 블록이며 Qwen의 가중치-어텐션을 재현한 것이 아닙니다. 기본 역할은 같지만 세부식을 섞어 그리면 안 됩니다.

6. 모델 계보: 세 갈래를 비교합니다



자체 제작. 세 패널 사이에 처리 순서가 있는 것이 아닙니다. 출발점은 2017 Transformer이며 BERT/GPT(2018), BART/T5(2019 연구 공개), 이후 Qwen 등으로 구조와 학습 방식이 다양해졌습니다. 단순한 한 줄의 후계 관계는 아닙니다.


비교 축	BERT	GPT / Qwen 기본 모델	T5 / BART
구조	encoder-only	decoder-only	encoder-decoder
self-attention 접근	입력의 앞뒤	현재까지의 토큰	인코더는 전체, 디코더는 현재까지
cross-attention	기본 구조에 없음	기본 텍스트 구조에 없음	디코더 Q가 인코더 K/V 참고
대표 사전학습 정답	가린 토큰, 원 BERT는 NSP도 사용	다음 토큰	T5: 가린 구간 / BART: 손상 전 문장 복원
잘 맞는 출발 과제	분류·토큰 라벨링·표현	이어쓰기·텍스트 생성	조건부 번역·요약·변환

생성을 한다고 모두 decoder-only는 아닙니다. T5도 생성합니다. 또 GPT/Qwen으로 분류를 수행할 수 있으므로 표는 “유일한 가능한 용도”가 아닙니다. **base와 instruct 구분은 encoder/decoder 구분과 별개**입니다. 이번 기본 Qwen은 대화 지시를 잘 따르도록 만든 챗봇이 아니라 이어쓰기 모델입니다.

구조 비교 근거: [Hugging Face LLM Course](#), [원논문](#). 실제 모델은 [고정 Qwen2-0.5B revision](#)을 사용합니다.

7. 사전학습과 생성: 정답이 있는가, 가중치를 바꾸는가?

학습: 정답을 한 칸 이동 · 미래는 가리고 모든 위치의 손실 계산



자체 제작. 단어 단위 개념 예시이며 실제 토크나이저 분할이 아닙니다. 입력 “나는 오늘 학교에”에 대해 위치별 정답은 “오늘 학교에 간다”입니다. 한 문장을 여러 위치의 학습 예제로 사용할 수 있습니다.

$$\mathcal{L} = -\frac{1}{T} \sum_{t=1}^T \log p_{\theta}(x_{t+1} \mid x_1, \dots, x_t).$$


θ 는 모델 가중치, T 는 정답이 있는 예측 위치 수입니다. 정답 확률 0.8이면 한 위치 손실은 약 0.223, 0.2이면 약 1.609입니다. 학습은 이 손실을 줄이는 방향으로 가중치를 바꿉니다. 정답이 원문에서 만들어지므로 사람이 모든 다음 단어를 별도로 표시할 필요가 없습니다.

단계	데이터/입력	가중치 갱신	이번 실습
사전학습	많은 텍스트와 자체 구성 정답	있음	이미 학습된 가중치를 다운로드
미세조정	목적에 맞는 추가 데이터	있음	수행하지 않음
추론	사용자 프롬프트	없음	실제 forward로 다음 토큰 선택

학습에서는 정답 토큰이 이미 있어 마스크를 쓰면서 여러 위치의 손실을 병렬 계산할 수 있습니다. 추론에서는 다음 입력에 넣을 토큰 자체를 아직 모르므로 한 번 선택한 결과를 다음 단계로 넘깁니다. 프롬프트에 예시를 추가하는 것만으로 가중치가 학습되지는 않습니다.

8. 실습: 한 단계에서 웹앱까지

추론: 방금 고른 토큰이 다음 단계 입력이 된다



EOS 또는 새 토큰 한도이면 종료 · 아니면 확장된 ID로 반복

자체 제작. `model.generate()`를 한 번 호출하는 대신 다음 과정을 직접 연결합니다.

1. 토큰화: 문자열 $\rightarrow$ ID tensor $[1, n]$.
2. 실제 forward: 전체 위치 로짓 $[1, n, V]$ 중 마지막 위치 $[V]$ 사용.
3. greedy 선택: 가장 큰 로짓의 ID 하나 선택.
4. ID 추가: $[1, n] \rightarrow [1, n+1]$. 문자열을 다시 토큰화하지 않음.
5. EOS 또는 새 토큰 한도이면 멈추고, 아니면 반복. 전체 ID열을 decode해 문장 표시.

여기서 V 는 어휘 크기 기호로서, 어텐션의 Value 행렬 V 와 문맥이 다릅니다. 후보 확률이 높다고 문장이 사실이라는 뜻도 아닙니다. greedy의 선택 확률 1은 선택 규칙의 결과일 뿐입니다.

Colab 실행 순서

새 W03B 사본을 Drive에 저장합니다. 패키지는 **0.1.4**, 고정 태그는 **2026-fall-w03b**입니다. W03A 사본과 기존 태그는 유지됩니다. CPU 기본, 유료 API 키·원자료 업로드는 필요 없습니다. 최초 공개 모델 약 1 GB 다운로드 뒤 캐시를 재사용합니다. 다운로드 오류를 가짜 결과로 대신하지 않습니다.

먼저 작은 NumPy 블록을 확인합니다. 그다음 모델을 한 번 준비하고 $s_0 \rightarrow s_1 \rightarrow s_2$ 를 직접 연결합니다. 마지막 짧은 반복문의 빈칸과 버튼 연결을 완성합니다. 문제를 못 풀어도 기본 관찰 앱은 독립적으로 실행됩니다.

웹 화면의 **초기화**는 프롬프트를 ID로 바꾸고 기록을 비웁니다. **다음 토큰 1개 추가**는 저장된 ID에 한 토큰만 붙입니다. 문장이나 한도를 바꾸면 다시 초기화해야 합니다. 사용자별 `gr.State`를 사용하므로 다른 세션의 생성 기록과 섞지 않습니다.

버튼	입력 → 함수	반환 → 화면
초기화	문장, 한도 → reset	새 상태, 원문, 빈 표, ready
다음 토큰	문장, 한도, 상태 → advance	새 상태, 누적 문장, 기록 표, 종료 상태
자동 생성(조립 활동)	문장, 한도 → 학생 callback	완성 문장, 표, 종료 이유

기본 앱은 `share=False`입니다. Colab 외부 공유는 노트북의 별도 선택 안내를 따릅니다. 공유 주소는 런타임이 종료되면 사용할 수 없고 영구 서비스가 아닙니다. 개인정보·비밀 정보를 입력하지 마세요. 모델 출력은 오류·편향을 포함할 수 있습니다.

9. 출구 질문

Q1. 잔차 덧셈에서 두 배열은 어떤 조건을 만족해야 하는가?

Q2. causal mask는 자기 자신도 가리는가? 미래 점수를 0으로 만들면 되는가?

Q3. 한 토큰을 고른 다음 forward에는 무엇을 넣는가?

추가 복습 질문:

- FFN과 어텐션은 어떻게 역할이 다른가?
- 두 개의 3×2 head를 concat하면 6×2 인가?
- T5가 문장을 생성하므로 decoder-only라고 할 수 있는가?
- 어텐션 표의 확률과 다음 토큰 확률의 정규화 축은 같은가?
- 추론 중 프롬프트 변경은 미세조정인가?

[퀴즈 해설](#)은 먼저 답을 말해 본 뒤 확인하세요. 별도 성적 반영 과제나 제출 기한은 없습니다.

부록: 차원을 한 번에 점검하기

연산	입력	출력	확인할 축
Q/K/V 투영	$X : 3 \times 4$, 각 $W : 4 \times 2$	각 3×2	마지막 특징 축
점수	$Q : 3 \times 2$, $K^T : 2 \times 3$	3×3	받는 위치 × 참고 위치
마스크·softmax	3×3	3×3	각 행 합 1
가중합	$A : 3 \times 3$, $V : 3 \times 2$	3×2	참고 위치를 합산
2 head concat	각 3×2	3×4	열 방향 결합

연산	입력	출력	확인할 측
출력 투영·잔차·LN	3×4	3×4	덧셈 모양 일치
FFN	3×4	$3 \times 6 \rightarrow 3 \times 4$	행은 독립, 가중치는 공유

예시 $X = [e_1; e_2; e_3] \in \mathbb{R}^{3 \times 4}$, $W_Q = W_K = [(1, 0); (0, 1); (1, 1); (0, 0)]$, $W_V = [(1, 0); (0, 2); (3, 1); (0, 0)]$ 로 두면 본문의 Q/K/V가 정확히 나옵니다. 모든 중간 배열과 두 head의 독립 가중치는 공개 `walkthrough.py`에서 확인합니다. 숫자를 임의로 부여한 교육용 블록이며 학습 결과로 해석하지 않습니다.