

CLIP 의미 검색과 확산 모델의 원리·학습 · 퀴즈 해설

W05B 기록지의 점검 질문과 정확히 대응하는 별도 복습 해설. 실습 조립 활동 정답과 구별한다.

1. Q1. CLIP에서 이미지와 문장을 각각 인코딩한 뒤 투영하는 이유는 무엇인가?

서로 다른 입력에서 얻은 내부 특징을 같은 공통 공간으로 옮겨 비교하기 위해서다. B/32 이미지 내부768차원은 투영 후512차원이며 텍스트도 학습된 투영을 거친다. 차원 수만 같다고 의미 정렬이 자동으로 이루어지는 것은 아니다.

2. Q2. 벡터 (3,4)와 (0,2)의 내적과 코사인은 각각 얼마인가?

내적은 8, 길이는 5와 2이므로 코사인은 $\frac{8}{5 \times 2} = 0.8$ 이다. 길이1로 정규화한 뒤 내적해도 0.8이다.

3. Q3. image_to_text와 text_to_image 표의 행은 각각 무엇을 뜻하는가?

image_to_text의 행은 이미지, 열은 문장이다. text_to_image는 전치한 뒤 행 softmax를 계산하므로 행은 문장, 열은 이미지다. 두 표 모두 각 행 합이1이다.

4. Q4. A의 코사인이 그대로인데 후보를 추가하면 softmax 점수가 달라지는 이유는 무엇인가?

softmax 분모는 현재 후보 전체의 $\exp(\text{logit})$ 합이다. A의 원래 코사인이 같아도 새 후보의 항이 추가되어 상대 점수가 바뀐다. 보정된 실제 정답 확률이라고 해석하지 않는다.

5. Q5. 관련 사진이 두 장뿐인 모음에서 P@3의 최댓값은 얼마이며, 없는 대상 검색도 결과가 나올 수 있는가?

최댓값은2/3이다. top-k는 현재 후보의 순위이므로 정답 대상이 없어도 결과를 반환한다. 관련 집합이 공집합이면 P@3은0이다.

6. Q6. alpha_bar=0.64, x0=0.5, epsilon=-1일 때 noisy 픽셀은 얼마인가?

$\sqrt{0.64} \times 0.5 + \sqrt{0.36} \times (-1) = 0.4 - 0.6 = -0.2$ 다. 계수는 분산 자체가 아니라 제곱근이다.

7. Q7. epsilon prediction 모델의 입력과 학습 정답은 무엇이며, 숫자 라벨은 사용되는가?

입력은 noisy 이미지 x_t 와 시점 t , 정답은 직접 뽑아 섞은 Gaussian epsilon이다. 정답 epsilon은 loss에 사용하며 `model.forward`에는 넣지 않는다. 숫자 클래스 라벨은 이 무조건부 학습에 쓰지 않는다.

8. Q8. backward와 optimizer.step은 각각 무엇을 바꾸는가?

`backward`는 모수의 gradient를 계산하며 모수 값은 그대로다. `optimizer.step`은 gradient와 optimizer 상태에 따라 모수를 실제로 갱신한다.

9. Q9. pred_original_sample과 prev_sample은 어떻게 다르며, 단순히 예측 잡음을 빼면 되는가?

`pred_original_sample`은 현재 상태에서 추정된 깨끗한 원본이고 `prev_sample`은 스케줄의 평균·분산에 따라 만든 다음 상태다. 신호·잡음 계수와 분산을 사용하므로 x_t 에서 예측 epsilon을 그냥 빼는 것과 다르다.

10. Q10. noise-MSE가 낮아졌다는 사실만으로 좋은 생성 품질을 단정할 수 없는 이유는 무엇인가?

noise-MSE는 지정한 시점·잡음에서의 예측 오차다. 생성물의 인식 가능성, 다양성, 애매한 획, 분포 누락을 모두 대변하지 않는다. 고정 평가 조건과 같은 seed·표본 수의 전체 생성 격자를 함께 보며, 소수 표본에서 FID를 과장하지 않는다.