

W06B · 1. 같은 잡음에서 원하는 이미지를 만들려면

2026-10-07 · 생성형 인공지능 · 주교재 『핸즈온 생성형 AI』 5.1

오늘의 질문은 다음과 같습니다. 잡음에서 출발하되, 운동화를 만들라고 지정하려면 무엇을 추가해야 할까? 지난 실습 파일을 실행하지 않았어도 이 노트와 새 Colab A에서 시작할 수 있습니다.

1. 지난 시간의 세 동작을 분리하기

확산 모델은 흐릿한 사진에 필터 하나를 적용하는 프로그램이 아닙니다. 학습 때는 정답을 알고 있는 손상 문제를 만들고, 생성 때는 배운 예측기를 반복 사용합니다.

과정	출발점	하는 일	바뀌는 것
전방 손상	실제 이미지와 우리가 뽑은 잡음	두 배열을 정해진 비율로 섞기	이미지 상태
학습	손상 이미지, 시점, 정답 잡음	예측과 정답의 차이로 역전파	모델의 가중치
생성	새로운 정규분포 잡음	예측기와 스케줄러를 반복 호출	생성 중인 이미지 상태


학습은 가중치, 생성은 상태를 바꾼다

두 경로를 따로 읽으세요. 클래스 조건 y 는 예측기의 입력이며 정답 잡음이 아닙니다.

학습



생성



그림의 아래쪽 생성 경로에는 정답 이미지가 없습니다. 학습된 가중치를 고정하고, 스케줄러가 예측을 해석하여 다음 상태를 계산합니다. U-Net 출력에서 단순히 잡음을 한 번 빼면 생성이 끝난다고 생각하지 마세요.

잠깐 확인 C1. 생성 버튼을 누를 때마다 `optimizer.step()`을 실행해야 할까요? 그림에서 근거를 찾아 설명하세요.


2. 데이터 선택과 조건 입력은 다릅니다

운동화 사진만 골라 비조건부 모델을 학습하면 운동화와 비슷한 결과를 만들 수 있습니다. 그러나 티셔츠로 바꾸려면 데이터와 학습 문제 자체를 바꿔야 합니다. 클래스 조건부 모델은 여러 클래스를 함께 학습하면서 원하는 클래스도 입력으로 받습니다.

모델	잡음 예측기의 입력	학습 정답	생성할 때 선택
비조건부	손상 이미지, 시점	추가했던 잡음	seed 등
클래스 조건부	손상 이미지, 시점, 클래스	추가했던 잡음	클래스와 seed 등
텍스트 조건부	손상 잠재변수, 시점, 텍스트 표현	이 수업의 SD 1.5에서는 잡음	프롬프트와 seed 등

라벨을 받는 인자를 함수에 붙이는 것만으로 조건부 모델이 되지는 않습니다. 라벨과 이미지의 관계를 사용하는 가중치가 **실제로 학습**되어야 합니다.

Fashion-MNIST · 실제 학습 데이터



출처: Zalando Research의 Fashion-MNIST. 각 이미지는 28×28 회색조입니다. 0 티셔츠/상의, 1 바지, 2 풀오버, 3 드레스, 4 코트, 5 샌들, 6 셔츠, 7 운동화, 8 가방, 9 앵클부츠입니다. 0-2-6처럼 육안으로도 구별하기 어려운 클래스가 있습니다.

3. 식에 라벨이 들어가도 정답은 잡음입니다

먼저 깨끗한 이미지 x_0 에 표준정규 잡음 ϵ 을 섞습니다.

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

클래스 조건부 예측기에는 y 를 추가합니다.

$$\mathcal{L}(\theta) = \mathbb{E}_{x_0, y, t, \epsilon} [\|\epsilon - \epsilon_\theta(x_t, t, y)\|_2^2]$$

기호	이번 실습에서의 실제 대상	예
x_0	[-1,1]로 변환한 이미지 배열	(B, 1, 28, 28)
t	잡음 수준을 가리키는 정수	(B,), 0-99
y	의류 클래스 번호	(B,), 0-9
ϵ	우리가 뽑아 정답으로 보관한 정규 잡음	(B, 1, 28, 28)
ϵ_θ	모델이 예측한 잡음	(B, 1, 28, 28)


실습의 MSE는 배치·채널·공간 원소 전체의 평균입니다. 식의 노름 제곱과 상수 배율은 다르지만 같은 예측 오차를 최소화합니다. 클래스 7과 예측 이미지의 픽셀 사이에 MSE를 계산하지 않습니다.

예를 들어 한 픽셀에서 신호 계수가 0.8, 잡음 계수가 0.6이고 원본이 0.5, 정답 잡음이 -1이라면 손상 값은 -0.2입니다. 모델이 -0.7을 예측했다면 해당 원소의 제곱 오차는 0.09입니다. 클래스 번호는 이 계산을 도와주는 입력입니다.

4. 클래스는 어디로 들어갈까?

클래스 번호도 학습 가능한 벡터로

수업 소형 모델: 시간 64차원 + 클래스 64차원 → 각 잔차 블록에 전달



수업의 TinyClassUNet은 클래스 번호를 64차원 벡터로 바꾸고 시간 임베딩에 더합니다. 합친 벡터를 각 합성곱 블록에 전달합니다. 이미지의 공간 정보는 U자형 경로와 skip 연결로 전달합니다. 이 그림은 수업의 소형 모델 설계이며, 뒤에서 볼 SD의 토큰별 교차 어텐션과 같은 구현은 아닙니다.

학습 코드의 의미는 다음 네 줄로 압축할 수 있습니다.


```
noisy = forward_noise(clean, timesteps, epsilon)
prediction = model(noisy, timesteps, labels)
loss = ((prediction - epsilon) ** 2).mean()
# 이어서 zero_grad → backward → optimizer.step
```

epsilon을 예측기의 입력으로 넣으면 정답을 미리 알려주는 샘플입니다. labels는 원하는 종류를 말해 주지만, 그 이미지에 실제로 추가한 잡음 값까지 알려주지는 않습니다.

잠깐 확인 C2. 클래스 번호를 모두 7로 바꾸면 어떤 텐서의 shape가 변할까요? 어떤 의미가 변할까요?


5. 같은 초기 잡음으로 조건만 바꿔 보기

실제 6,000회 학습 모델 · DDIM30
같은 열은 초기 잡음 동일, 클래스만 변경



위 그림은 실제 학습한 수업 모델의 결과입니다. 각 열의 seed는 42-45로 고정하고, 같은 열에서는 클래스만 바꿨습니다. 생성 결과는 저해상도이며 일부 의류는 모호합니다. 원하는 클래스와 관계 있는 모양이 나타나는지, 클래스 간 혼동이 남는지 함께 봅니다. 잘 나온 한 장만 골라 모델 전체 성능이라고 주장하지 않습니다.

Colab A에서는 새 모델을 32번 짧게 갱신해 실제 학습 동작을 확인합니다. 그 뒤 **6,000번 갱신한 별도 제공 체크포인트**를 로드합니다. 32회 실습으로 위 결과가 나왔다고 해석하면 안 됩니다. 체크포인트의 학습 시간·분할·seed·손실 기록은 노트북에서 직접 읽습니다.



잡음 MSE는 예측 과제의 지표입니다. 의류가 자연스럽고 다양한지를 직접 나타내는 점수는 아닙니다. 생성 결과의 관찰과 함께 해석하세요.

6. 실습에서 확인할 세 가지

1. 손실은 유한한가? `backward()` 후에는 `gradient`가 생기고 `optimizer.step()` 뒤에는 가중치가 실제로 바뀌는가?
2. 같은 seed·모델·생성 단계에서 클래스만 바꿨는가? 초기 잡음 배열이 정말 같은가?
3. 관찰한 모양과 해석을 구별했는가? “클래스 7에서 밀창처럼 보이는 선이 생겼다”는 관찰, “모든 운동화를 잘 생성한다”는 아직 검증하지 않은 일반화입니다.

다음 노트에서는 이 이미지 공간 계산을 더 작은 **잠재 공간**으로 옮깁니다.

참고: 주교재 5.1; [Fashion-MNIST 원자료](#); [수업 함수 정의 색인](#).