W10A · 계산·실험·설명 기록지

2026-11-02 · 『핸즈온 생성형 AI』 6.4–6장 끝

강의노트와 독립 Colab A/B를 함께 사용합니다. 먼저 예상하고 실제 출력·중간값을 관찰한 뒤, 한 조건을 바꾼 이유와 결과의 한계를 적습니다. 완성 예제는 읽고 이해한 다음 가리고 다시 설명합니다. 이번 기록은 학습과 자기 점검용이며 새 성적 과제·마감은 없습니다.

필수 활동 A · LoRA·양자화·통합

A1 · 차원과 모수 수를 계산하기

W0는2차원 단위행렬, x=(1,-1), A=(2,1), B=(1,3)의 세로벡터, r1, alpha2입니다. Ax → BAx → 스케일 → 기본 출력과의 합을 순서대로 계산하세요. 각 단계의 shape도 적습니다. 이 작은 층에서 전체 학습과 LoRA의 학습 모수 수가 줄어드는지도 비교하세요.

힌트: B와A의 곱은 입력/출력 차원을 연결하며, alpha와alpha/r는 구별합니다. 큰 모델의 절감 비율을 이 작은 예에서 그대로 기대하지 않습니다.

A2 · 실제 학습의 증거 찾기

기본 모델/어댑터의 requires_grad, 전후 해시·변화량, 첫 두 단계의 A/B 기울기를 근거로 어떤 가중치가 변했는지 설명하세요. 같은 greedy 문장이 출력돼도 학습이 있었을 수 있는지 생각해 보세요. 어댑터 저장·같은 base revision 재로딩·float 병합이 확인하는 대상을 구별합니다.

힌트: 학습이 작동했다는 증거와 품질이 좋아졌다는 평가는 다른 질문입니다.

A3 · 이상치 하나와 양자화 오차

(0.1,0.2,0.3,1)과(0.1,0.2,0.3,100)을4bit로 비교합니다. 같은 앞의 세 값이 왜 다르게 복원되는지 step과 반올림으로 설명하세요. bits만8로 바꿔 다시 비교하고, 영벡터 처리와 q 배열의 실제 dtype도 확인합니다. 가중치 저장량의 하한을 실제 peak RAM이라고 부를 수 있는지도 기록하세요.

힌트: s는 이번 구현에서 복원에 곱하는 격자 간격입니다. 이 균등 정수 실험은 NF4가 아닙니다.

A4 · 마스크 오류를 고치고 앱에 설명 연결하기

다음 두 설명의 오류를 고치세요: "ID가PAD와 같으면 진짜EOS도 모두 지운다", "labels를 수집기에서 한 칸 이동하고 모델에도 labels로 준다." QLoRA의 기본 가중치와 학습 어댑터를 나누고 저장/계산/어댑터 dtype을 읽습니다. 사전 실행 기록 분석과 현재 런타임의 실제4bit 실행도 구별합니다.

마지막으로 `learner_note(prediction, observation, limitation)`를 작성해 세 입력 위젯과 출력에 연결합니다. 위젯 입력 순서를 바꾸면 어느 연결을 함께 바꿔야 하는지 적으세요.

힌트: 문제용 변수와 기본 모델 실행 변수는 분리돼 있습니다. 아직 빈칸을 완성하지 못해도 다음 기본 실험을 진행할 수 있습니다.

필수 활동 B · 평가·RAG·앱

B1 · 분모와 평가 반례

평균NLL0.8인 유효토큰3개와 평균NLL1.4인9개의 전체NLL/PPL을 손으로 구한 뒤 함수와 대조하세요. 참조와 단어가 비슷하지만 시각이 틀린 답, 표현은 다르지만 같은 사실을 전하는 답을 구별할 사람 평가 기준을 작성합니다.

힌트: 배치 수와 유효 토큰 수를 혼동하지 말고 근거 정확성·질문 응답성·형식을 나눕니다.

B2 · 검색에서 실제 답까지 추적하기

세미나의 요일·시각·장소를 묻는 질문에서 top-k 문서의ID/점수/내용을 읽으세요. 관련 문서가 검색됐는지와 모델이 세 가지 사실을 모두 정확히 답했는지를 따로 판정합니다. `retrieved`, `used_document_ids`, `dropped_document_ids`, `input_tokens`도 대조합니다.

힌트: 문서ID 출력이나 높은cosine 점수만으로 답변 정답을 인정하지 않습니다.

B3 · 문서 한 조건 변경과 근거 없는 질문

같은 질문·생성기·greedy·k를 유지한 상태에서 D01의18:00을20:00으로 바꿉니다. 재임베딩·인덱스 버전·실제 문맥·출력의 어느 부분이 바뀌었는지 적으세요. 출력이 시각을 누락하거나 그대로여도 검색/생성 단계의 성공과 실패를 분리해 기록합니다. 문서에 없는 출입코드를 물었을 때 어떤 응답이 타당한지도 설명하세요.

힌트: 문서 갱신은 생성기 가중치 학습이 아닙니다. 작은 생성기의 실패를 정답 문자열로 덮어쓰지 않습니다.

B4 · 앱 기록과 새 사례 전이

질문·k·문맥 조건 위젯에서 callback과 같은lab객체를 거쳐 표/문맥/응답/JSON으로 이어지는 연결을 설명합니다. 자신의 설명 함수를 연결하고 입력·관찰·근거·한계가 구별되는지 확인하세요.

"매주 바뀌는 최신규정", "항상한줄JSON을 출력해야 하는 작업", "모델 저장 메모리 부족"이라는 새 상황에 방법과 평가를 어떻게 조합할지 설계합니다. 한 가지 방법만 배타적으로 고를 필요는 없습니다.

선택 확장

ID	확장할 비교/설계	고정하거나 확인할 조건
X1	rank2와4의 실제 짧은 LoRA 비교	alpha/r=2, 같은base/seed/분할/길이/학습량/lr 일정
X2	지원 장치의 실제4bit 추가 실행	실제4bit계층·기본동결·유한loss·어댑터갱신·버전/장치
X3	top-k1/3과 문맥 예산 비교	같은질문/생성기, 실제 사용ID·토큰·출력. 임베딩 변경 시 인덱스 재구성
X4	이미지 분류 도전의 입력/라벨/평가 전이	AutoImageProcessor, 이미지 원본 단위 분리, 클래스ID/헤드 대응

GPU/T4·새 임베딩 모델·전체ViT/Food101 학습을 실행하지 않았다면 설계 또는 미검증으로 표시합니다. 기본 CPU실습 성공을 그 실행 증거로 바꾸지 않습니다.

교재 장말 복습 대응

다음은 교재295쪽 연습7개와296쪽 도전의 **요지를 정리한 대응표**입니다. 원문 표현과 수업용 확장 설명은 구별합니다. 교재 번호를 유지하므로 책과 함께 복습할 수 있습니다.

교재 번호	복습할 질문의 요지	이번 자료의 연결
T1 · 연습1	기본 모델과 파인튜닝 모델의 차이, 대화형 모델의 위치	지난6.1–6.3 연결, SFT/채팅템플릿
T2 · 연습2	어떤 작업에서 기본 인코더를 골라 파인튜닝하는가	문장분류/개체명/표현과 생성모델의 작업 적합성
T3 · 연습3	파인튜닝·인스트럭트 튜닝·QLoRA의 구별	네 축 지도, 6.6통합
T4 · 연습4	어댑터가 모델 크기에 미치는 영향	선택층 모수 수, 저장/재로딩/float병합
T5 · 연습5	70B의16/8/4bit 가중치 메모리 계산	완성예제E5, GB/GiB와실행메모리 구별
T6 · 연습6	QLoRA의 학습 속도 저하 이유와 조건	복원/커널/장치/전송 overhead, 실제측정
T7 · 연습7	파인튜닝 중 가중치를 고정할 수 있는 상황	PEFT/특징추출/부분미세조정과학습대상
T8 · 이미지 도전	tokenizer에서image processor로, 이미지분류 파인튜닝 설계	X4, 입력[B,3,H,W]/labels[B]/클래스매핑·데이터누출

T6의 교재 질문은 속도 저하를 전제로 하지만, 실제 속도는 장치·커널·배치·기본모델 로드·연산량에 좌우됩니다. 항상 더 느리다/빠르다고 일반화하지 않고 같은 조건에서 측정합니다. 교재 참고자료는 장의 추가 읽기 길잡이이며 과거 성능/순위를 현재 수치라고 재사용하지 않습니다.

나의 실험 기록

활동	실행 전 예측	실제 중간값/출력	바꾼 조건·고정 조건	이유·한계·새 사례 설명
A1/A2				
A3/A4				
B1/B2				
B3/B4				

자가 점검은 가중치 갱신 대상, 저장/계산의 구별, 비교 조건, 근거와 한계를 중심으로 합니다. "출력만 봄 → 중간값으로 이유를 설명함 → 새 상황에 필요한 방법과 검증을 설계함"으로 설명의 범위를 넓혀 보세요.

복습 점검 Q1–Q10

먼저 자신의 말로 답한 뒤 별도의 퀴즈 해설과 비교하세요. 아래 문항은 실습 활동과 별도로 공개 개념 해설을 제공합니다.

1. SFT, LoRA, 양자화, RAG를 같은 분류의 배타적 선택지로 보면 왜 틀리는가?
2. LoRA에서 $W_0 \in \mathbb{R}^{d\times k}$, $A \in \mathbb{R}^{r\times k}$, $B \in \mathbb{R}^{d\times r}$의 곱과 학습 모수 수는 어떻게 연결되는가?

3. A 랜덤/B=0 초기화에서 첫 A 기울기가0이어도 학습 실패가 아닌 이유는 무엇인가?
4. absmax 균등 양자화에서 이상치 하나가 작은 값의 복원에 영향을 주는 이유는 무엇인가?
5. $\frac{Pb}{8}$로 계산한 가중치 저장량과 실제 실행 메모리를 구별해야 하는 이유는 무엇인가?
6. QLoRA의 기본4bit 저장, 계산 dtype, 학습 어댑터를 어떻게 구별하는가?
7. 실제EOS와PAD의 ID가 같을 때 응답-only loss 마스크는 무엇을 보존해야 하는가?
8. PPL의 유효 토큰 분모와 BLEU/ROUGE의 겹침이 사실성 평가를 대신하지 못하는 이유는 무엇인가?
9. RAG에서 검색hit와 답변의 근거 일치를 따로 확인해야 하는 이유는 무엇인가?
10. 문서를 갱신하는 RAG와 LoRA SFT는 무엇을 바꾸며 각각 어떤 검증이 필요한가?

참고자료

『핸즈온 생성형 AI』 6.4–6.9와 장말 문제. 상세 출처와 모델/논문 링크는 강의노트 참고자료에 있습니다. 문제와 수계산·가상 데이터·비교 실험은 수업용으로 새로 작성했습니다.